

Dylan Rifqi Alfaizi

uas_pm_dylan_15745.docx

 Subclass 1
 13-20 Juli 2026
 Universitas Dian Nuswantoro

Document Details

Submission ID**trn:oid::1:3611626074****Submission Date****Jul 15, 2026, 11:24 AM GMT+7****Download Date****Jul 15, 2026, 11:51 AM GMT+7****File Name****uas_pm_dylan_15745.docx****File Size****2.7 MB****49 Pages****6,067 Words****40,401 Characters**

13% Overall Similarity

The combined total of all matches, including overlapping sources, for each database.

Filtered from the Report

- Bibliography

Top Sources

- 10%  Internet sources
 - 8%  Publications
 - 5%  Submitted works (Student Papers)
-

Top Sources

- 10% Internet sources
- 8% Publications
- 5% Submitted works (Student Papers)

Top Sources

The sources with the highest number of matches within the submission. Overlapping sources will not be displayed.

1	Internet	kc.umn.ac.id	<1%
2	Internet	repository.umsu.ac.id	<1%
3	Student papers	Universiti Teknikal Malaysia Melaka	<1%
4	Publication	Anindya Khrisna Wardhani, Rano Indradi Sudra, Ega Nugraha, Astrid Novita Putri....	<1%
5	Internet	eprints.umk.ac.id	<1%
6	Internet	jurnal.polibatam.ac.id	<1%
7	Publication	Achmad Hakim Qoirul Haq, Harminto Mulyo, Adi Sucipto. "Optimasi Kinerja Algor...	<1%
8	Student papers	Islington College,Nepal	<1%
9	Student papers	Universitas Atma Jaya Yogyakarta	<1%
10	Internet	dspace.uir.ac.id	<1%
11	Internet	santika.upnjatim.ac.id	<1%

12	Publication	Jayadi Jayadi, Vito Hafizh Cahaya Putra, Agung Rachmat Raharja, Muhammad Al...	<1%
13	Publication	Maulana Ichsan Ichsan. "IMPLEMENTASI MACHINE LEARNING UNTUK DETEKSI PE...	<1%
14	Internet	repository.upi.edu	<1%
15	Publication	Ahmad Miftakhudin, Nugroho Adhi Santoso, Bayu Aji Santoso. "Komparasi Algotir...	<1%
16	Internet	crossweb.pl	<1%
17	Internet	ejurnal.stmik-budidarma.ac.id	<1%
18	Internet	repo.darmajaya.ac.id	<1%
19	Internet	adoc.pub	<1%
20	Publication	Luthfia Nurma Hapsari, Ilham Fannani, Yenny Rahmawati, Ahmad Muhariya. "Ex...	<1%
21	Student papers	Universitas Kristen Duta Wacana	<1%
22	Internet	etheses.uin-malang.ac.id	<1%
23	Internet	repository.ub.ac.id	<1%
24	Internet	docobook.com	<1%
25	Publication	Alvina Jelita Firdaus, Zaehol Fatah. "Disease Risk Prediction Using the Random Fo...	<1%

26	Publication	Erika Adelia Pratiwi, Sita Muharni. "PENERAPAN ALGORITMA RANDOM FOREST U...	<1%
27	Student papers	Universitas Muhammadiyah Palembang	<1%
28	Student papers	Universitas Putera Batam	<1%
29	Internet	repository.ummat.ac.id	<1%
30	Publication	Nirwan Yakub, Leni Marlina, Muhammad Iqbal, Andysah Putera Utama Siahaan, ...	<1%
31	Internet	repository.ar-raniry.ac.id	<1%
32	Internet	repository.umb.ac.id	<1%
33	Publication	Ananda Rizki Dani, Irma Handayani. "Classification of Yogyakarta Batik Motifs Usi...	<1%
34	Student papers	Universitas Dian Nuswantoro	<1%
35	Internet	ejurnal.provisi.ac.id	<1%
36	Internet	journals.gesociety.org	<1%
37	Internet	repository.unas.ac.id	<1%
38	Internet	repository.unbari.ac.id	<1%
39	Publication	Berliano Kurniawan, Fikri Budiman. "Model Pembelajaran Mesin untuk Deteksi G...	<1%

40	Publication	Madhurie Kumar Seth, K. Srinivas, A. Charan Kumari. "Classifying fungi biodiversi...	<1%
41	Publication	Sri Wahyuni, Rossi Passarella. "ANALISIS MODEL PREDIKSI UNTUK LAYANAN BUS ...	<1%
42	Publication	Teguh Muryanto, Aji Nurrohman, Rachmat Setiabudi, Wibisono Wibisono, Berliya...	<1%
43	Publication	Zian Asti Dwiyantri, Cahyo Prianto. "Prediksi Cuaca Kota Jakarta Menggunakan Me...	<1%
44	Internet	repository.unissula.ac.id	<1%
45	Internet	repository.ut.ac.id	<1%
46	Internet	rstudio-pubs-static.s3.amazonaws.com	<1%
47	Internet	www.coursehero.com	<1%
48	Publication	Novandra Hanifah Najlawarni, Tukino Paryono, Fitria Nurapriani, Baenil Huda. "K...	<1%
49	Internet	e-journal.hamzanwadi.ac.id	<1%
50	Internet	ejournal.ust.ac.id	<1%
51	Internet	ejurnal.seminar-id.com	<1%
52	Internet	es.scribd.com	<1%
53	Internet	journal.stekom.ac.id	<1%

54	Internet	repositori.uma.ac.id	<1%
55	Internet	repository.uin-suska.ac.id	<1%
56	Internet	www.ejournal.unma.ac.id	<1%
57	Publication	Kemal Hapidz Prastiawan, Dwi Yuniarto. "Analisis Sentimen Publik terhadap Prog...	<1%
58	Publication	Melania Velisita Lau, Aryani Dwi Handayani, Miyosagusti Yudo Widodo, Rani Irma...	<1%
59	Publication	Wilianto Wilianto, Yuliana Yuliana, Albert Suwandhi, Jimmy Jimmy, Jati Putra. "Pe...	<1%

PROPOSAL PROYEK

ANALISIS DAN PREDIKSI PERFORMA KONTEN VLOG YOUTUBE

MENGGUNAKAN MACHINE LEARNING

Disusun Untuk Melaksanakan Ujian Tengah Semester Genap

Mata Kuliah Pembelajaran Mesin



Disusun oleh:

DYLAN RIFQI ALFAIZI

NIM: A11.2024.15745

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS DIAN NUSWANTORO

2026

DAFTAR ISI

Ringkasan dan Kata Kunci	vi
BAB I.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	1
1.3 Pendekatan Solusi.....	2
1.4 Batasan Masalah	2
1.5 Tujuan Penelitian.....	2
1.6 Manfaat Penelitian.....	3
1.7 Keunggulan Penelitian	3
1.8 Roadmap Penelitian.....	4
.....	4
BAB II	6
2.1 Penelitian Terdahulu.....	6
2.2 Landasan Teori	8
2.2.1 YouTube dan Viralitas Konten.....	8
2.2.2 Machine Learning.....	8
2.2.3 Klasifikasi.....	8
2.2.4 Random Forest	9
2.2.8 Dataset YouTube Trending Videos	11
2.2.9 Data Preprocessing	12
2.2.10 Confusion Matrix	13
2.2.11 Accuracy.....	15
2.2.12 Precision	15
2.2.13 Recall.....	15

2.2.14 F1-Score	16
-----------------------	----

2.3 Kerangka Berpikir	16
-----------------------------	----

BAB III.....	18
---------------------	-----------

3.1 Tahapan Penelitian	18
------------------------------	----

3.1.1 Studi Literatur.....	19
----------------------------	----

3.1.2 Pengumpulan Dataset	19
---------------------------------	----

3.1.3 Data Preprocessing	19
--------------------------------	----

3.1.4 Pelatihan Model.....	19
----------------------------	----

3.1.5 Pengujian Model.....	19
----------------------------	----

3.1.6 Evaluasi Model.....	20
---------------------------	----


3.1.7 Analisis Hasil	20
----------------------------	----

3.2 Studi Pustaka	20
-------------------------	----

3.3 Kebutuhan Pengguna.....	21
-----------------------------	----

3.4 Dataset	21
-------------------	----

3.5 Pra-pemrosesan Data	23
-------------------------------	----




3.6 Perancangan Model	23
-----------------------------	----

3.7 Skenario Eksperimen.....	26
------------------------------	----

3.8 Metode Evaluasi	27
---------------------------	----

8

3.8.1 Accuracy	27
3.8.2 Precision	28
3.8.3 Recall	28
3.8.4 F1-Score	29
3.8.5 Confusion Matrix	29
3.6 Eksperimen	30



3.6 Skenario Pengujian	30
4.1 Implementasi Sistem	32
4.1 Spesifikasi Teknis	32
4.2 Fungsionalitas Aplikasi	32
4.3 Target Pengguna	33
4.2 Hasil Pelatihan dan Pengujian	33
4.2.1 Confusion Matrix	34
4.3 Analisis Hasil	34
4.3.1 Analisis Feature Importance	35
4.4 Perbandingan Eksperimen	35
4.5 Pembahasan	36
4.6 Keterbatasan Penelitian	36
5.1 Luaran	Error! Bookmark not defined.

37

5.2 JADWAL PENELITIAN	Error! Bookmark not defined.
6.1 Kesimpulan.....	38
6.2 Saran.....	39
DAFTAR PUSTAKA.....	40

DAFTAR GAMBAR

Gambar 1.5 Diagram Roadmap Penelitian	2
Gambar 2.4 Diagram Pra Pemrosesan Data	5
Gambar 2.5 Perbandingan Training Set Vs Testing Set	6

DAFTAR TABEL

Tabel 2.1 Perbandingan Algoritma Machine Learning	4
Tabel 2.3 Deskripsi Dataset YouTube.....	5
Tabel 2.6 Hasil Performa Model pada Training dan Testing Set.....	6
Tabel 3.1 Metrik Evaluasi Model	8

Ringkasan dan Kata Kunci

Di tengah persaingan ketat antar kreator di ekosistem digital, YouTube menjadi salah satu panggung utama tempat ratusan ribu pembuat konten berlomba menghasilkan tayangan yang mampu menjangkau audiens luas. Meski demikian, mekanisme di balik sebuah video hingga dapat menjadi viral masih belum sepenuhnya terpetakan. Sejumlah kajian terdahulu memperlihatkan bahwa keterlibatan penonton, terutama dalam bentuk likes dan komentar, menjadi salah satu penanda kuat tingkat kepopuleran konten digital [1, 2]. Bertolak dari hal tersebut, proyek ini disusun untuk melihat kemungkinan memprediksi status viral suatu video berdasarkan sejumlah metrik interaksi, yaitu jumlah likes, jumlah komentar, dan kategori video yang bersangkutan.

Data yang dipakai bersumber dari berkas `clean_youtube_data.csv` yang memuat kurang lebih 40.000 catatan video [3]. Alur kerja diawali dari pembersihan data, dilanjutkan dengan penelusuran pola statistik, hingga akhirnya sampai pada pembangunan model klasifikasi berbasis Random Forest. Pemilihan algoritma ini didasari oleh sejumlah pertimbangan praktis: kemampuannya mengolah hubungan data yang tidak linear, ketersediaan analisis feature importance sebagai alat interpretasi, dan pendekatan ensemble yang membuatnya relatif tahan terhadap overfitting [4]. Pengujian model dilakukan melalui empat metrik utama—akurasi, presisi, recall, dan F1-score—dan diperoleh angka akurasi 95,58% pada data uji. Dari hasil tersebut terlihat bahwa jumlah likes dan komentar menjadi dua variabel paling dominan dalam menentukan status viral suatu konten.

Manfaat praktis dari proyek ini terletak pada tersedianya alat bantu analitik yang bisa dimanfaatkan content creator maupun pemasar digital ketika menyusun strategi konten berbasis data. Sebagai wujud nyata, dibangun pula sebuah prototipe berbasis Streamlit, sebuah framework yang memudahkan penerapan model machine learning secara interaktif tanpa harus membangun infrastruktur backend yang rumit [5].

Kata Kunci: analitik YouTube; pembelajaran mesin; prediksi viralitas; Hutan Acak; metrik keterlibatan.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perubahan pola konsumsi media di era digital tidak lepas dari peran platform seperti YouTube, yang saat ini menaungi lebih dari 2,7 miliar pengguna aktif dan menjadi ruang utama bagi content creator maupun brand untuk menjangkau penonton lintas negara. Namun kenyataannya, tidak semua unggahan mampu meraih perhatian yang cukup untuk disebut viral—hanya sebagian kecil video yang benar-benar berhasil menembus popularitas besar, sedangkan mayoritas lainnya hanya ditonton oleh segmen audiens yang terbatas [2]. Kesenjangan ini sering kali muncul karena kreator belum memanfaatkan pendekatan berbasis data (data-driven) secara maksimal dalam merancang strategi kontennya.

Di sinilah pembelajaran mesin berperan, yaitu membantu mengenali pola dari variabel-variabel seperti likes, komentar, dan kategori video yang berkaitan dengan kemunculan konten viral. Beberapa penelitian sebelumnya bahkan sudah membuktikan bahwa algoritma berbasis ensemble semacam Random Forest dan XGBoost sanggup memprediksi tingkat popularitas video YouTube dengan akurasi yang cukup tinggi, mengandalkan metadata dan data keterlibatan pengguna [1, 6]. Pemanfaatan analisis prediktif semacam ini membuka peluang bagi kreator untuk menyusun strategi konten yang lebih terarah, sekaligus memberi ruang bagi platform untuk menghadirkan rekomendasi yang lebih relevan bagi penggunanya.

1.2 Rumusan Masalah

- Faktor apa yang paling berpengaruh terhadap viralitas video YouTube?
- Apakah machine learning dapat memprediksi apakah video tersebut akan viral atau tidak?
- Seberapa akurat prediksi dengan model yang dibangun?

1.3 Pendekatan Solusi

Alur penyelesaian masalah dimulai dari pengolahan awal data YouTube, mencakup pembersihan, penyesuaian skala, dan pemetaan variabel. Tahap berikutnya adalah membangun model klasifikasi berbasis Random Forest, yang kemudian diperiksa performanya lewat metrik akurasi dan F1-score. Sebagai pelengkap, analisis feature importance dimanfaatkan untuk menelusuri faktor mana yang paling berperan dalam menentukan kinerja sebuah video [4, 6].

1.4 Batasan Masalah

- Dataset ini menggunakan YouTube Trending Videos Dataset yang berasal dari Kaggle.
- Fitur yang digunakan hanya mencakup Likes, jumlah komentar, dan ID kategori.
- Prediksi dibatasi pada klasifikasi Viral dan Non-Viral.
- Algoritma yang digunakan adalah Random Forest.
- Penilaian dilakukan dengan menggunakan metrik Accuracy, Precision, Recall, dan F1-Score.

1.5 Tujuan Penelitian

- Membangun model machine learning menggunakan algoritma Random Forest untuk memprediksi viralitas video YouTube.
- Mengevaluasi kemampuan model dengan menggunakan metrik Accuracy, Precision, Recall, dan F1-Score.
- Menganalisis faktor yang mempengaruhi viralitas video berdasarkan feature importance.

1.6 Manfaat Penelitian

- Teoritis

Menambah referensi penelitian yang berhubungan dengan prediksi viralitas konten digital menggunakan machine learning.


- Praktis

Membantu content creator dan digital marketer dalam mengoptimalkan strategi konten.

1.7 Keunggulan Penelitian

- Fokus prediksi apakah konten akan viral atau tidak viral menggunakan dataset besar.
- Pendekatan yang seimbang antara analisis faktor dan evaluasi kinerja model.
- Implementasi dalam bentuk prototipe dashboard interaktif untuk kreator konten menggunakan framework Streamlit [5].
- Tingkat akurasi lebih dari 95% yang lebih baik dibandingkan dengan penelitian serupa menggunakan Logistic Regression atau Decision Tree [4].

1.8 Roadmap Penelitian



Gambar 1.5 Diagram Roadmap Penelitian

Pengembangan model prediksi viralitas konten YouTube pada penelitian ini disusun melalui beberapa tahapan berurutan, dimulai dari penelusuran literatur sampai pada analisis hasil akhir, sebagaimana digambarkan pada diagram berikut.

- Studi Literatur: Menelaah sejumlah referensi seputar machine learning, terutama algoritma klasifikasi Random Forest [4], serta merujuk penelitian-penelitian terdahulu yang membahas analisis performa konten digital [1, 2, 6].
- Pengumpulan dan Pemrosesan Data: Dataset diambil dari platform Kaggle [3], kemudian melewati serangkaian pengolahan awal berupa pembersihan data, penyisihan entri tidak valid, penanganan nilai kosong, hingga penyesuaian format.
- Pelatihan Model Machine Learning: Algoritma Random Forest dilatih agar mampu membedakan video viral dari yang non-viral berdasarkan pola pada data.

30

- Evaluasi Model: Kinerja model diukur lewat empat metrik—accuracy, precision, recall, dan F1-score—guna memastikan tingkat akurasi dan keandalannya sudah memadai.
- Pengembangan Dashboard Prediksi Viralitas: Sebuah prototipe aplikasi web dibangun memakai Streamlit [5], memungkinkan pengguna memasukkan data video secara langsung dan segera memperoleh hasil prediksinya.
- Analisis Hasil: Tahap penutup berupa penarikan kesimpulan dari seluruh temuan, mencakup faktor-faktor penentu viralitas serta sejauh mana efektivitas model yang telah dibangun.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

No	Peneliti	Metode	Hasil
1	Hsiao et al. (2025)	Random Forest	Akurasi 94%
2	Gupta et al. (2024)	XGBoost	Akurasi 96%
3	Liu et al. (2025)	Ensemble Learning	Akurasi 95%
4	Muqri et al. (2025)	Random Forest	Akurasi 93%

Keempat studi pada tabel di atas menggambarkan bahwa algoritma machine learning secara konsisten mampu diandalkan untuk memprediksi popularitas maupun kinerja konten digital, khususnya di platform YouTube. Pada penelitian Hsiao dkk. (2025), penerapan Random Forest untuk memprediksi popularitas video menghasilkan akurasi 94%, sementara Gupta dkk. (2024) memperoleh angka lebih tinggi, yaitu 96%, dengan memanfaatkan XGBoost. Sementara itu, pendekatan

Ensemble Learning yang digunakan Liu dkk. (2025) mencatatkan akurasi sebesar 95%, dan Muqri dkk. (2025) yang juga mengandalkan Random Forest namun dengan fokus pada tingkat keterlibatan video, memperoleh akurasi 93%.

Kesamaan pola pada keempat studi tersebut mengarah pada satu kesimpulan: algoritma berbasis ensemble, terutama Random Forest, cenderung unggul ketika berhadapan dengan data yang relasinya kompleks dan tidak linear. Selain unggul dari sisi akurasi, karakteristik lain yang menjadikannya menarik adalah kemampuannya menekan risiko overfitting sekaligus menyediakan gambaran tentang seberapa penting kontribusi masing-masing fitur dalam proses analisis.

Merujuk pada temuan-temuan tersebut, penelitian ini pun memutuskan menggunakan Random Forest sebagai algoritma utama untuk memprediksi tingkat viralitas video YouTube, dengan tiga fitur sebagai pertimbangan yaitu Likes, jumlah komentar, dan ID kategori. Keputusan ini bukan tanpa alasan—rekam jejak algoritma tersebut pada studi-studi sebelumnya menunjukkan kemampuannya yang konsisten baik dalam mengolah data maupun menjelaskan faktor-faktor yang berkontribusi terhadap viralitas suatu konten.

2.2 Landasan Teori

2.2.1 YouTube dan Viralitas Konten

Sebagai salah satu platform berbagi video terbesar, YouTube memfasilitasi penggunaanya untuk mengunggah, menonton, dan membagikan berbagai jenis konten, dengan jumlah pengguna aktif yang mencapai miliaran setiap bulannya berdasarkan laporan resmi platform tersebut. Istilah viralitas sendiri mengacu pada fenomena ketika sebuah video mengalami lonjakan penyebaran dan respons penonton dalam waktu relatif singkat. Beberapa indikator yang lazim dipakai untuk mengukur tingkat viralitas suatu konten antara lain jumlah likes, jumlah komentar, jumlah penonton, kategori video, hingga tingkat keterlibatan (engagement) secara keseluruhan.

2.2.2 Machine Learning

Sebagai salah satu cabang dari kecerdasan buatan, machine learning memungkinkan sistem komputer mengenali pola dari data yang tersedia, kemudian memanfaatkan pola tersebut untuk menghasilkan prediksi tanpa perlu diprogram secara eksplisit di setiap kasus [4,5]. Pada konteks penelitian ini, pendekatan tersebut diterapkan untuk mengelompokkan video ke dalam dua kategori, viral dan non-viral, dengan memperhitungkan karakteristik yang melekat pada masing-masing video.

2.2.3 Klasifikasi

48 Termasuk dalam kelompok pembelajaran terpandu (supervised learning), klasifikasi bertujuan mengelompokkan data ke sejumlah kategori tertentu berdasarkan pola yang sudah dipelajari lebih dulu dari data latihan. Bentuk klasifikasi yang dipakai pada penelitian ini adalah klasifikasi biner, dengan label 1 untuk kategori viral dan label 0 untuk kategori non-viral [4].

2.2.4 Random Forest

15 Algoritma Random Forest memanfaatkan sekumpulan pohon keputusan yang dibangun secara independen untuk menghasilkan keputusan klasifikasi. Setiap pohon memperoleh kombinasi data dan fitur yang berbeda sehingga mampu menghasilkan sudut pandang prediksi yang beragam. Hasil keluaran dari seluruh pohon kemudian dikombinasikan untuk menentukan keputusan akhir yang dianggap paling representatif. Pendekatan tersebut membuat model memiliki ketahanan yang lebih baik terhadap variasi data serta mampu mempertahankan performa prediksi pada berbagai kondisi dataset.

Salah satu karakteristik utama Random Forest adalah penggunaan pemilihan sampel dan atribut secara acak selama proses pembelajaran. Strategi ini menghasilkan keberagaman antar pohon yang berperan penting dalam meningkatkan kemampuan generalisasi model. Dengan demikian, risiko model menghafal pola data pelatihan dapat diminimalkan sehingga performa pada data baru cenderung lebih stabil.

Ketika data baru diberikan, masing-masing pohon akan menghasilkan prediksi secara independen. Selanjutnya, seluruh prediksi tersebut dikombinasikan menggunakan mekanisme *majority voting* untuk menentukan kelas akhir. Dengan cara ini, kesalahan yang mungkin terjadi pada satu pohon dapat dikurangi oleh pohon lainnya sehingga tingkat keandalan model meningkat.

Beberapa kelebihan Random Forest antara lain mampu menangani hubungan yang kompleks antar variabel, memiliki performa yang baik pada data berukuran besar, relatif tahan terhadap data yang mengandung noise, serta dapat memberikan

informasi mengenai tingkat kontribusi setiap fitur terhadap hasil prediksi. Namun demikian, penggunaan banyak pohon keputusan menyebabkan kebutuhan komputasi menjadi lebih besar dibandingkan algoritma klasifikasi yang lebih sederhana.

20 Dalam penelitian ini, Random Forest digunakan untuk mengidentifikasi apakah suatu video YouTube termasuk kategori viral atau non-viral berdasarkan nilai Likes, Comment Count, dan Category ID. Pemilihan algoritma ini didasarkan pada kemampuannya dalam menghasilkan prediksi yang akurat sekaligus menyediakan analisis feature importance untuk mengetahui faktor yang paling memengaruhi viralitas video.

Keunggulan utama Random Forest antara lain:

1. Memiliki tingkat akurasi yang tinggi pada berbagai kasus klasifikasi.
2. Mampu menangani data dengan hubungan non-linear.
3. Lebih tahan terhadap data yang mengandung noise atau outlier.
4. Mengurangi risiko overfitting karena menggunakan banyak pohon keputusan.
5. Dapat menampilkan tingkat kepentingan fitur (*feature importance*) sehingga membantu dalam interpretasi model.

52 Dengan demikian, Random Forest mempunyai beberapa kelemahan, yaitu memerlukan waktu komputasi yang lebih lama dibandingkan dengan algoritma yang lebih sederhana serta menghasilkan model yang lebih sulit untuk diinterpretasikan dibandingkan dengan model pohon keputusan tunggal.

59 Secara ringkas, alasan Random Forest dipakai pada penelitian ini adalah karena kesanggupannya membedakan video viral dari non-viral berbekal fitur jumlah likes, jumlah komentar, dan kategori video, sekaligus menawarkan gambaran mengenai fitur mana yang paling berpengaruh terhadap penyebaran video lewat analisis pentingnya fitur.

2.2.8 Dataset YouTube Trending Videos

Secara umum, dataset berfungsi sebagai bahan baku yang dipakai untuk melatih sekaligus menguji sebuah model machine learning. Sumber data pada penelitian ini adalah YouTube Trending Videos Dataset yang tersedia di platform Kaggle [3], berisi rekaman video-video yang pernah masuk daftar trending YouTube dari berbagai negara, pada rentang waktu November 2017 sampai Januari 2019.

Sebelum diolah, dataset ini memuat 48.967 entri video. Setelah melewati tahap pembersihan—menyingkirkan data duplikat, menangani nilai kosong, dan merapikan format—jumlahnya menyusut menjadi 40.848 data valid yang selanjutnya dipakai pada penelitian ini. Volume data sebesar itu dinilai cukup memadai dan memuat informasi yang relevan untuk menganalisis kinerja serta tingkat popularitas video di YouTube.

Ada tiga variabel input yang dipakai, yakni jumlah likes, jumlah komentar, dan ID kategori, sementara variabel targetnya berupa Viral Status—label yang menandai apakah sebuah video termasuk kategori viral atau non-viral.

Atribut	Deskripsi
Sumber Data	https://www.kaggle.com/datasets/datasnaek/youtube-new [3]
Total Record	48.967 entri video
Data Valid	40.848 video (setelah cleaning)
Fitur Input	Likes, Comment Count, Category ID
Target	Viral Status (1 = Viral, 0 = Non-Viral)

Atribut	Deskripsi
Distribusi	Viral: 86,99%, Non-Viral: 13,01%
Rentang Waktu	November 2017 – Januari 2019

2.2.9 Data Preprocessing

Sebelum data dipakai untuk melatih model, terdapat tahap persiapan yang dikenal sebagai data preprocessing. Tujuannya adalah menaikkan kualitas dataset agar informasi yang nantinya diproses oleh model lebih konsisten, relevan, dan terbebas dari gangguan yang berpotensi mengganggu hasil prediksi.

Langkah awal preprocessing pada penelitian ini adalah memeriksa kualitas data guna menemukan entri yang tidak lengkap, terduplikasi, atau atribut yang sebetulnya tidak diperlukan. Barulah setelah itu format data disesuaikan agar tiap variabel bisa diolah secara optimal oleh algoritma klasifikasi.

Menyusul tahap tersebut, dipilihlah fitur-fitur yang dianggap punya keterkaitan dengan viralitas video. Dari sekian banyak atribut yang tersedia, hanya Likes, Comment Count, dan Category ID yang dijadikan variabel masukan, dengan pertimbangan agar model lebih fokus pada faktor-faktor yang benar-benar relevan dengan tujuan penelitian.

Ketiga fitur tersebut kemudian distandardisasi memakai metode StandardScaler, dengan tujuan menyeragamkan rentang nilai sehingga tidak ada atribut yang secara tidak adil mendominasi proses pelatihan model.

Sebagai penutup rangkaian preprocessing, dataset dipecah menjadi data pelatihan (80%) dan data pengujian (20%) memakai teknik stratified sampling, sehingga proporsi kelas viral maupun non-viral tetap terjaga di kedua kelompok. Dengan cara ini, proses pelatihan dan evaluasi model bisa berjalan di atas representasi data yang lebih seimbang [4,5].

Pada penelitian ini, tahapan preprocessing yang dilakukan meliputi:

1. Data Cleaning

Proses pembersihan data mencakup pembuangan kolom-kolom yang tidak diperlukan, entri duplikat, serta baris yang tidak memiliki nilai (missing value), sehingga kualitas data yang dipakai lebih terjamin.

2. Konversi Tipe Data

Sejumlah atribut dikonversi ke format numerik supaya bisa diolah oleh algoritma pembelajaran mesin, mengingat kebanyakan algoritma klasifikasi hanya dapat bekerja dengan data berbentuk angka.

3. Feature Selection

Di antara seluruh atribut yang tersedia, hanya Likes, jumlah komentar, dan ID kategori yang dipilih karena dianggap paling berkaitan dengan tingkat viralitas video.

4. Feature Scaling

Skala tiap fitur numerik diseragamkan lewat metode StandardScaler, sehingga algoritma pembelajaran mesin lebih mudah mengenali pola-pola pada data.

5. Data Splitting

Terakhir, dataset dibagi menjadi data pelatihan (80%) dan data pengujian (20%) memakai metode Stratified Sampling, agar komposisi kelas viral maupun non-viral tetap proporsional di kedua bagian.

2.2.10 Confusion Matrix

Confusion Matrix adalah salah satu cara mengevaluasi performa model klasifikasi, yaitu dengan membandingkan hasil prediksi terhadap kondisi aktualnya. Dibanding sekadar melihat angka akurasi, teknik ini memberi gambaran yang jauh lebih detail

karena mampu menunjukkan jenis-jenis kesalahan yang dibuat model selama proses klasifikasi berlangsung.

Ketika klasifikasi dilakukan pada dua kelas, hasil prediksi model bisa dipilah ke dalam empat kelompok, tergantung sejauh mana prediksi tersebut cocok dengan kondisi sebenarnya. Kelompok pertama, True Positive (TP), menandai video viral yang berhasil dikenali dengan tepat oleh model. Kelompok kedua, True Negative (TN), menandai video non-viral yang juga berhasil diklasifikasikan secara benar. Di luar prediksi yang tepat, ada pula dua bentuk kesalahan yang mungkin terjadi. False Positive (FP) muncul saat video sebenarnya non-viral tetapi diprediksi model sebagai viral, sedangkan False Negative (FN) terjadi sebaliknya—video yang sejatinya viral justru gagal dikenali dan dianggap non-viral. Gabungan keempat komponen ini menjadi dasar untuk melihat gambaran utuh performa model klasifikasi.

Keempat angka TP, TN, FP, dan FN inilah yang selanjutnya menjadi dasar perhitungan berbagai indikator performa model. Lewat nilai-nilai tersebut, peneliti bisa menakar tingkat ketepatan prediksi sekaligus kemampuan model mengenali tiap kategori yang ada. Dengan kata lain, Confusion Matrix tak sekadar menghitung berapa prediksi yang benar, tapi juga menyingkap pola kesalahan yang masih tersisa pada proses klasifikasi.

Pada penelitian ini, Confusion Matrix dipakai untuk mengukur seberapa baik Random Forest membedakan video viral dari non-viral. Hasil pengelompokan yang diperoleh lantas ditelaah lebih jauh untuk melihat tingkat keberhasilan prediksi sekaligus jenis kesalahan yang paling kerap muncul sepanjang tahap pengujian.

Pada klasifikasi biner, confusion matrix terdiri dari empat komponen utama, yaitu:

Prediksi	Aktual Positif	Aktual Negatif
Prediksi Positif	True Positive (TP)	False Positive (FP)
Prediksi Negatif	True Positive (TP)	True Negative (TN)

Keterangan:

- **True Positive (TP)** adalah jumlah data viral untuk prediksi viral.
- **True Negative (TN)** adalah jumlah data non-viral untuk prediksi non-viral.
- **False Positive (FP)** adalah jumlah data non-viral untuk prediksi viral.
- **False Negative (FN)** adalah jumlah data viral untuk prediksi non-viral.

2.2.11 Accuracy

Accuracy menggambarkan seberapa besar proporsi prediksi yang tepat dibandingkan keseluruhan data yang diuji [1,4].

Rumus:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2.2.12 Precision

Precision mencerminkan seberapa tepat model saat memprediksi kelas positif [1,4].

Rumus:

$$Precision = \frac{TP}{TP + FP}$$

2.2.13 Recall

Recall menunjukkan sejauh mana model sanggup menangkap seluruh data yang sebenarnya termasuk kelas positif [1,4].

Rumus:

$$Recall = \frac{TP}{TP + FN}$$

2

2.2.14 F1-Score


F1-Score adalah nilai rata-rata harmonik dari Precision dan Recall, dipakai untuk melihat keseimbangan antara keduanya [1,4].

Rumus:

$$F1 = 2 \frac{Precision \times Recall}{Precision + Recall}$$

2.3 Kerangka Berpikir

Diagram:



Gambar 2.3 Diagram Kerangka Berpikir

Diagram di atas memetakan alur kerja penelitian dalam membangun model prediksi viralitas video YouTube berbasis Random Forest. Rangkaian proses diawali dengan pengumpulan dataset video trending dari Kaggle, yang kemudian melewati tahap preprocessing—mulai dari pembersihan data, penentuan fitur yang relevan, normalisasi, hingga pemisahan menjadi data pelatihan dan data pengujian.

Begitu preprocessing rampung, data tersebut dipakai untuk membangun model klasifikasi Random Forest. Model yang telah terlatih ini selanjutnya berfungsi memprediksi peluang sebuah video menarik perhatian publik, dengan mempertimbangkan fitur jumlah Likes, jumlah komentar, dan kategori ID.

27 Tahap berikutnya adalah mengukur performa model lewat metrik Accuracy, Precision, Recall, dan F1-Score, dilengkapi dengan analisis feature importance untuk melihat faktor mana yang paling berpengaruh terhadap viralitas video. Dari evaluasi dan analisis inilah bisa disimpulkan seberapa andal Random Forest dalam memprediksi kinerja konten vlog di YouTube.

31 BAB III

METODE PENELITIAN

3.1 Tahapan Penelitian

Proses penelitian ini dirancang secara sistematis dengan sasaran akhir berupa model machine learning yang mampu memprediksi peluang sebuah video YouTube menjadi viral, bertumpu pada data keterlibatan pengguna. Alurnya berjalan

bertahap, dimulai dari penelusuran materi-materi terkait hingga akhirnya sampai pada penilaian terhadap performa model yang dihasilkan.

Secara umum, tahapan penelitian yang dilakukan meliputi:

3.1.1 Studi Literatur

Tahap ini berisi penelusuran berbagai referensi seputar machine learning, algoritma Random Forest, evaluasi kinerja konten digital, serta hasil-hasil penelitian terdahulu yang masih relevan [1,2,4,6,7], sebagai landasan teori dan metode yang akan dipakai sepanjang penelitian.

3.1.2 Pengumpulan Dataset

Sumber dataset yang dipakai berasal dari Kaggle, tepatnya kumpulan data video trending di YouTube yang memuat informasi berbagai video dari daftar trending lintas negara.

3.1.3 Data Preprocessing

Rangkaian aktivitas pada tahap ini meliputi pembersihan data duplikat, penanganan nilai kosong, pemilihan fitur relevan, standardisasi data, hingga pembagian dataset menjadi bagian pelatihan dan pengujian.

3.1.4 Pelatihan Model

Algoritma yang dipakai untuk melatih model adalah Random Forest. Pada tahap ini, model mempelajari keterkaitan antara fitur input dengan tingkat viralitas video.

3.1.5 Pengujian Model

Setelah proses pelatihan rampung, model diuji dengan data yang belum pernah dilihat sebelumnya, guna memastikan sejauh mana kemampuannya melakukan generalisasi pada data baru.

7

3.1.6 Evaluasi Model

Empat metrik—Accuracy, Precision, Recall, dan F1-Score—dipakai untuk menilai performa model, dilengkapi Confusion Matrix agar hasil prediksi lebih mudah dipahami.

3.1.7 Analisis Hasil

Sebagai penutup, hasil evaluasi ditelaah lebih dalam untuk menemukan faktor-faktor yang berpengaruh terhadap viralitas video, merujuk pada nilai feature importance yang dihasilkan Random Forest.

3.2 Studi Pustaka

Berikut gambaran singkat beberapa algoritma yang lazim dipakai untuk menilai performa konten:

- Regresi Logistik: mudah diinterpretasikan dan cocok untuk data yang hubungannya linier, tetapi kurang optimal ketika berhadapan dengan data non-linear.
- Pohon Keputusan/Hutan Acak (Random Forest): relatif tahan terhadap noise maupun nilai ekstrem pada data, sekaligus punya tingkat interpretabilitas yang cukup baik.
- Peningkatan Gradient/XGBoost: menawarkan performa yang lebih unggul, namun proses tuning parameternya lebih rumit dan menuntut ketelitian ekstra.

Ada tiga pertimbangan utama di balik pemilihan Random Forest untuk penelitian ini: pertama, akurasi cukup baik pada kasus klasifikasi biner (viral/non-viral); kedua, tersedia analisis feature importance untuk melihat kontribusi tiap fitur; dan ketiga, risiko overfitting bisa ditekan berkat pendekatan ensemble learning [4]. Sejalan dengan itu, penelitian lain yang memanfaatkan video titles bersama

Random Forest untuk memprediksi engagement YouTube juga menunjukkan hasil yang lebih unggul dibanding algoritma pembanding lainnya [7].

Algoritma	Akurasi Rata-Rata	Kompleksitas	Interpretabilitas
Logistic Regression	85 – 88%	Rendah	Tinggi
Decision Tree	90 – 92%	Sedang	Baik
Random Forest	94 – 96%	Sedang	Baik
XGBoost	95 – 97%	Tinggi	Sedang

Tabel 2.1. Perbandingan Algoritma Machine Learning [4]

3.3 Kebutuhan Pengguna

- **Content Creator:** Memperoleh wawasan mengenai faktor-faktor penentu viralitas sebagai dasar pengembangan strategi konten yang efektif.
- **Agensi Digital Marketing:** Mengoptimalkan kampanye video berdasarkan prediksi performa untuk meningkatkan hasil pemasaran.
- **Platform Analis YouTube:** Memanfaatkan model prediksi untuk mendukung sistem rekomendasi algoritmik yang lebih akurat dan relevan.


3.4 Dataset

Atribut	Deskripsi
Sumber Data	https://www.kaggle.com/datasets/datasnaek/youtube-new

Atribut	Deskripsi
	[3]
Total Record	48.967 entri video
Data Valid	40.848 video (setelah cleaning)
Fitur Input	Likes, Comment Count, Category ID
Target	Viral Status (1 = Viral, 0 = Non-Viral)
Distribusi	Viral: 86,99%, Non-Viral: 13,01%
Rentang Waktu	November 2017 – Januari 2019

Tabel 3.4 Deskripsi Dataset YouTube [3]

3.5 Pra-pemrosesan Data



Gambar 3.5 Diagram *Pra Pemrosesan Data*

Tahapan pra-pemrosesan data yang dilakukan adalah sebagai berikut:

- Membuang kolom kosong (Unnamed) beserta baris data yang terduplikasi.
- Membersihkan nilai NaN sekaligus mengubah tipe data menjadi numerik.
- Menstandarisasi fitur numerik memakai metode StandardScaler.
- Memisahkan data menjadi set pelatihan (80%) dan set pengujian (20%) memakai teknik stratified sampling agar proporsi kelas tetap terjaga.

3.6 Perancangan Model

Tujuan dari tahap perancangan model adalah membangun sistem klasifikasi yang bisa menentukan apakah sebuah video YouTube tergolong viral atau tidak, ditinjau dari karakteristik yang melekat pada video tersebut.

Algoritma yang dipilih sebagai model utama pada penelitian ini adalah Random Forest Classifier, mengingat kesanggupannya mengolah data berpola tidak linear, menekan risiko overfitting, sekaligus memberi gambaran seberapa penting

kontribusi masing-masing fitur.

Ada tiga variabel input yang menyusun model ini, yaitu:

- Likes
- Comment Count
- Category ID


Sedangkan variabel target yang digunakan adalah:

- Viral Status (1 = Viral, 0 = Non-Viral)

Sebelum pelatihan model dilakukan, data terlebih dahulu mengalami proses preprocessing yang mencakup pembersihan data, **standardisasi fitur numerik**, serta pemisahan **data** lalu **menjadi** bagian **training** dan **testing**.

Proses klasifikasi dilakukan dengan menggunakan metode Random Forest, yang membangun beberapa pohon keputusan berdasarkan subset data yang dipilih secara acak. Setiap pohon memberikan prediksi berdasarkan data yang diberikan, lalu semua hasil prediksi tersebut digabungkan melalui metode majority voting.

Diagram aliran desain model dapat dinyatakan sebagai berikut:



Gambar 3.6 Diagram Perancangan Model

3.7 Skenario Eksperimen

Pengujian pada tahap ini bertujuan mengukur seberapa baik algoritma Random Forest mampu memperkirakan tingkat viralitas video YouTube dengan memanfaatkan fitur-fitur yang telah tersedia pada dataset.

Adapun rangkaian tahapan eksperimen yang ditempuh mencakup hal-hal berikut:

1. Mengumpulkan YouTube Trending Videos Dataset sebagai sumber data utama.
2. Membersihkan data serta melakukan tahap pra-pemrosesan.
3. Menetapkan Likes, Comment Count, dan Category ID sebagai variabel masukan model.
4. Menstandarkan data dengan bantuan StandardScaler.
5. embagi dataset menjadi 80% untuk data pelatihan dan 20% untuk data pengujian.
6. Melatih model Random Forest dengan memanfaatkan data pelatihan yang telah disiapkan.
7. Menerapkan model hasil pelatihan tersebut untuk memprediksi data uji.
8. Menghitung skor Accuracy, Precision, Recall, dan F1-Score dari hasil prediksi.
9. Melakukan analisis terhadap hasil evaluasi beserta tingkat feature importance-nya.

Rincian konfigurasi eksperimen yang diterapkan pada penelitian ini disajikan pada tabel berikut.

Parameter	Nilai
Dataset	YouTube Trending Videos Dataset
Jumlah Data	40.848 Data
Training Set	80%
Testing Set	20%
Random State	42
Metode Split data	Stratified Sampling
Algoritma	Random Forest
Metode Evaluasi	Accuracy, Precision, Recall, F1-Score

Tabel 3.7 Skenario Eksperimen

Pemilihan metode Stratified Sampling dimaksudkan agar perbandingan data viral dan non-viral tetap terjaga proporsinya, baik pada bagian pelatihan maupun pengujian, sehingga model dapat belajar dari pola data secara lebih optimal.

3.8 Metode Evaluasi

Tahap evaluasi dilaksanakan untuk mengukur kemampuan model Random Forest dalam mengelompokkan video YouTube ke dua kelas, yakni viral dan non-viral. Proses ini memanfaatkan data uji yang sama sekali belum dilibatkan pada tahap pelatihan model.

Empat metrik pokok dipakai sebagai acuan evaluasi pada penelitian ini, yakni Akurasi, Presisi, Rekall, dan Skor F1, dan dilengkapi dengan Confusion Matrix untuk melihat sebaran hasil klasifikasi model.

3.8.1 Accuracy

Accuracy dipakai untuk melihat seberapa besar proporsi prediksi yang tepat dibandingkan keseluruhan data uji.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Gambar 3.8.1 Rumus Accuracy

3.8.2 Precision

Precision menggambarkan sejauh mana ketepatan model saat memprediksi kelas viral.

$$Precision = \frac{TP}{TP + FP}$$

Gambar 3.8.2 Rumus Precision

3.8.3 Recall

Recall menunjukkan kemampuan model dalam menemukan video-video yang sesungguhnya viral.

$$Recall = \frac{TP}{TP + FN}$$

Gambar 3.8.3 Rumus Recall

3.8.4 F1-Score

F1-Score merupakan rata-rata harmonik dari Precision dan Recall, dipakai untuk melihat keseimbangan antara kedua metrik itu.

$$F1 = 2 \frac{Precision \times Recall}{Precision + Recall}$$


Gambar 3.8.4 Rumus F1- Score

3.8.5 Confusion Matrix

Confusion matrix dipakai untuk menelaah hasil klasifikasi dengan melihat jumlah True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN). Melalui matriks ini, pola kesalahan yang dibuat model dapat dipahami lebih jelas sehingga kinerja model bisa dianalisis secara lebih mendalam.

Gabungan metrik Accuracy, Precision, Recall, F1-Score, dan Confusion Matrix memungkinkan penilaian yang lebih menyeluruh terhadap efektivitas algoritma Random Forest dalam memprediksi tingkat viralitas video YouTube.

3.6 Eksperimen



Gambar 3.6 Perbandingan Training Set Vs Testing Set

Tahap eksperimen mencakup proses pelatihan sekaligus pengujian model machine learning guna memperkirakan viralitas video YouTube. Random Forest Classifier [4] dipilih sebagai model utama karena keunggulannya dalam mengolah data yang bersifat non-linear dan menekan risiko overfitting lewat pendekatan ensemble. Rancangan eksperimen ini ditujukan untuk mengetahui sebaik apa model mengelompokkan video ke kategori viral maupun non-viral.

3.6 Skenario Pengujian

Metrik	Training Set	Testing Set	Gap
Accuracy	99,96%	95,58%	4,38%
Precision	99,96%	97,10%	2,86%
Recall	100,00%	97,85%	2,15%
F1-Score	99,98%	97,47%	2,51%

Tabel 3.6 Skenario Pengujian

Secara umum, model Random Forest memperlihatkan performa yang cukup tinggi baik pada set pelatihan maupun set pengujian. Selisih yang tergolong kecil di antara keduanya menandakan model memiliki kemampuan generalisasi yang memadai

tanpa mengalami overfitting yang berarti [4], sekaligus menunjukkan keseimbangan yang baik antara bias dan variansi.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Implementasi Sistem

Pada tahap implementasi sistem, model machine learning yang sudah dibangun diterapkan ke dalam sebuah aplikasi berbasis web sebagai bentuk prototipe dengan antarmuka yang dapat langsung digunakan pengguna. Framework Streamlit dipilih karena dapat mengintegrasikan model machine learning secara langsung tanpa memerlukan infrastruktur backend yang rumit, sehingga sesuai untuk kebutuhan prototipe penelitian ini [5].

4.1 Spesifikasi Teknis

- Streamlit digunakan sebagai kerangka kerja pembuatan antarmuka web yang interaktif [5]
- Scikit-learn dimanfaatkan sebagai pustaka untuk pemrosesan model klasifikasi
- Pandas dan NumPy berperan sebagai pustaka untuk mengolah dan mentransformasi data masukan
- Matplotlib dan Seaborn digunakan sebagai pustaka visualisasi untuk hasil prediksi serta feature importance

4.2 Fungsionalitas Aplikasi

- **Input Data Video:** pengguna dapat memasukkan sendiri metrik video, mencakup jumlah likes, jumlah komentar, dan kategori video, sebagai parameter untuk prediksi.
- **Prediksi Viralitas:** sistem mengolah data masukan melalui model Random Forest yang telah dilatih, kemudian menghasilkan status prediksi viralitas (viral atau non-viral) beserta confidence score dalam rentang 0–100% [4].

- **Visualisasi Faktor Dominan:** aplikasi menyajikan grafik feature importance yang memperlihatkan besarnya kontribusi tiap variabel masukan terhadap hasil prediksi yang dihasilkan.

4.3 Target Pengguna

Prototipe aplikasi ini dirancang untuk memenuhi kebutuhan tiga kelompok pengguna utama [8]:

- Kreator konten independen yang membutuhkan acuan berbasis data untuk menyusun strategi kontennya.
- Agensi pemasaran digital yang memerlukan alat bantu untuk memperkirakan potensi performa video sebelum diunggah.
- Peneliti maupun analis platform yang menggunakan model prediktif ini sebagai bahan studi lebih lanjut.

4.2 Hasil Pelatihan dan Pengujian

Proses pelatihan memakai 80% dari keseluruhan data sebagai himpunan latih, sementara 20% sisanya dijadikan himpunan uji. Setelah model Random Forest rampung dilatih, pengujian dilakukan terhadap data uji tersebut untuk melihat kemampuan model mengklasifikasikan data yang belum pernah dilihat selama pelatihan.

Ringkasan hasil evaluasi model dapat dilihat pada tabel berikut.

Metrik	Training Set	Testing Set
Accuracy	99,96%	95,58%
Precision	99,96%	97,10%
Recall	100,00%	97,85%
F1-Score	99,98%	97,47%

Tabel 4.2 Hasil Evaluasi Model Random Forest

Berdasarkan hasil pengujian, model Random Forest menunjukkan performa yang baik baik pada data pelatihan maupun data pengujian. Selisih nilainya yang tergolong kecil mengindikasikan bahwa model ini mempunyai kemampuan generalisasi yang memadai.

4.2.1 Confusion Matrix

Confusion matrix diterapkan untuk mengamati sebaran prediksi yang benar maupun yang keliru. Rincian confusion matrix pada data testing adalah sebagai berikut:

- True Negative (TN) = 854 → jumlah data non-viral yang tepat diprediksi sebagai non-viral.
- False Positive (FP) = 208 → data non-viral yang justru diprediksi sebagai viral.
- False Negative (FN) = 153 → data viral yang keliru diprediksi sebagai non-viral.
- True Positive (TP) = 6.955 → jumlah data viral yang berhasil diprediksi dengan tepat sebagai viral.

Dari hasil tersebut, model mampu mengklasifikasikan 6.955 data sebagai true positive dan 854 data sebagai true negative. Angka false negative yang tergolong rendah (153) memperlihatkan bahwa model sudah cukup baik dalam menangkap sebagian besar video yang memang viral.

4.3 Analisis Hasil

Tahap analisis ini bertujuan mengenali faktor-faktor yang turut memengaruhi kemampuan model Random Forest dalam memprediksi video.

Hasil evaluasi memperlihatkan model ini memperoleh akurasi sebesar 95,58%, presisi 97,10%, recall 97,85%, dan skor F1 97,47%. Capaian tersebut

mengindikasikan model cukup mampu membedakan video yang viral dari yang tidak viral.

Tingginya nilai Recall menandakan model dapat mendeteksi sebagian besar video viral yang terdapat pada dataset, sedangkan nilai presisi yang tinggi menunjukkan bahwa mayoritas video yang diprediksi viral memang benar-benar tergolong viral.

Temuan ini memperlihatkan bahwa algoritma Random Forest cukup efektif memanfaatkan pola pada fitur likes, jumlah komentar, dan kategori video untuk memperkirakan tingkat viralitas.

4.3.1 Analisis Feature Importance

Hasil analisis feature importance menunjukkan bahwa jumlah likes memberi kontribusi terbesar, yakni 52,47%, sehingga menjadi penentu utama potensi viralitas sebuah video. Fitur jumlah komentar menyusul dengan kontribusi 41,53%, sedangkan category ID hanya menyumbang 6,00%. Pola ini sejalan dengan penelitian-penelitian sebelumnya yang menunjukkan bahwa likes dan komentar merupakan indikator keterlibatan pengguna paling dominan terhadap viralitas konten [2, 6, 8]. Dengan kata lain, tingkat engagement pengguna, terutama melalui likes dan komentar, menjadi penentu utama viralitas suatu video.

4.4 Perbandingan Eksperimen

Metrik	Training Set	Testing Set	Selisih
Accuracy	99,96%	95,58%	4,38%
Precision	99,96%	97,10%	2,86%
Recall	100,00%	97,85%	2,15%
F1-Score	99,98%	97,47%	2,51%

Tabel 4.4 Hasil Perbandingan Eksperimen Training dan Testing Set

Model Random Forest menunjukkan performa yang sangat baik pada data training maupun data testing. Perbedaan nilai yang relatif kecil antara keduanya mengindikasikan kemampuan generalisasi yang baik dan tidak terjadi overfitting secara signifikan [4], yang menandakan keseimbangan optimal antara bias dan variansi.

4.5 Pembahasan

Temuan penelitian ini memperlihatkan bahwa algoritma Random Forest memiliki performa klasifikasi yang cukup baik, khususnya dalam memperkirakan tingkat viralitas video YouTube. Nilai Accuracy, Precision, Recall, dan F1-Score yang tinggi mencerminkan kemampuan model dalam mengenali keterkaitan antara likes, jumlah komentar, dan kategori video terhadap tingkat viralitasnya.

Jumlah likes menjadi faktor paling menentukan apakah suatu video berpeluang viral atau tidak, yang mengindikasikan bahwa tingkat kepuasan penonton berkaitan erat dengan keberhasilan video tersebut.

Di samping itu, jumlah komentar turut berperan penting karena mencerminkan intensitas interaksi dan keterlibatan penonton terhadap konten. Semakin aktif partisipasi penonton, semakin besar pula peluang video tersebut menjangkau perhatian yang lebih luas.

Temuan ini sejalan dengan penelitian-penelitian terdahulu yang menyatakan bahwa metrik keterlibatan seperti likes dan komentar menjadi indikator penting dalam memperkirakan popularitas konten digital.

4.6 Keterbatasan Penelitian

Terdapat sejumlah keterbatasan pada penelitian ini yang dapat menjadi bahan pertimbangan bagi pengembangan penelitian berikutnya.

- Dataset yang dipakai hanya berasal dari video-video yang pernah masuk daftar trending YouTube, sehingga belum merepresentasikan keseluruhan video pada platform tersebut.
- Penelitian ini baru memanfaatkan tiga fitur utama, yakni jumlah like, jumlah komentar, dan ID kategori, padahal masih banyak faktor lain yang turut memengaruhi kecepatan sebuah video menjadi viral, misalnya jumlah tayangan, durasi video, judul, thumbnail, dan waktu publikasi.
- Algoritma yang diterapkan pada penelitian ini baru sebatas Random Forest, sehingga perbandingan dengan algoritma machine learning lain belum dilakukan.
- Data yang digunakan pada penelitian ini masih terbatas pada data numerik, sedangkan data berupa teks maupun visual yang terkandung dalam video belum dimanfaatkan.
- Model yang dikembangkan masih bersifat klasifikasi biner sehingga hanya mampu menentukan status viral atau non-viral suatu konten, tanpa dapat mengukur tingkat popularitasnya secara lebih rinci.

Mengacu pada berbagai keterbatasan tersebut, penelitian selanjutnya diharapkan dapat mengembangkan model yang lebih kompleks, menambah keragaman fitur, serta membandingkan beberapa algoritma machine learning agar diperoleh performa yang lebih optimal.

BAB V

PENUTUP

5.1 Kesimpulan

Mengacu pada hasil penelitian mengenai analisis dan prediksi kinerja konten vlog YouTube menggunakan algoritma Random Forest, dapat dirumuskan beberapa kesimpulan sebagai berikut:

1. Algoritma Random Forest terbukti dapat dipakai untuk memprediksi tingkat viralitas video YouTube dengan mempertimbangkan fitur Likes, jumlah komentar, dan ID kategori. Model yang dibangun mampu mengelompokkan video ke dalam kategori viral dan non-viral dengan hasil yang cukup memuaskan.
2. Berdasarkan data pengujian, model Random Forest memperoleh akurasi 95,58%, presisi 97,10%, recall 97,85%, dan skor F1 97,47%, yang menandakan model memiliki kemampuan cukup baik dalam mengenali pola sebaran viralitas video YouTube.
3. Analisis feature importance memperlihatkan fitur Likes memberi kontribusi terbesar pada proses prediksi (52,47%), diikuti Comment Count (41,53%), sementara Category ID hanya menyumbang 6,00%. Hal ini menegaskan bahwa keterlibatan pengguna memegang peran

penting dalam menentukan kecepatan dan luasnya sebaran viralitas sebuah video.

4. Perbandingan antara data pelatihan dan data pengujian memperlihatkan selisih yang tidak terlalu besar, sehingga menandakan model memiliki kemampuan generalisasi yang baik tanpa mengalami overfitting yang berlebihan.
5. Integrasi model ke dalam aplikasi berbasis Streamlit memberi kemudahan bagi pengguna untuk melakukan prediksi viralitas video secara interaktif dan sederhana, sekaligus membantu proses analisis kinerja konten YouTube.

5.2 Saran

Mengacu pada hasil penelitian ini, terdapat beberapa saran yang dapat dijadikan dasar pengembangan penelitian selanjutnya, antara lain:

1. Menambahkan fitur-fitur lain yang berpotensi memengaruhi kecepatan viralitas video, seperti jumlah tayangan, durasi video, waktu penerbitan, judul, dan tampilan thumbnail, sehingga prediksi model menjadi lebih tepat dan akurat.
2. Menggunakan dataset yang lebih luas dan beragam agar model dapat mengenali pola penyebaran konten YouTube secara lebih mendalam dan menyeluruh.
3. Menguji algoritma machine learning lain, seperti Decision Tree, Logistic Regression, XGBoost, atau Neural Network, untuk mengetahui algoritma mana yang memberikan performa prediksi viralitas video paling baik.
4. Mengembangkan penelitian ke arah data teks dan visual, misalnya menganalisis judul video, deskripsi, komentar pengguna, serta thumbnail dengan memanfaatkan pendekatan Natural Language Processing (NLP) dan Computer Vision.
5. Mengembangkan aplikasi prediksi yang lebih komprehensif dengan menambahkan fitur visualisasi data, rekomendasi strategi konten, dan

integrasi langsung dengan platform YouTube, agar dapat membantu content creator maupun digital marketer mengambil keputusan yang lebih tepat.

Melalui pengembangan-pengembangan tersebut, penelitian selanjutnya diharapkan mampu menghasilkan model prediksi viralitas yang lebih akurat dan fleksibel, memberi manfaat yang lebih luas bagi pengguna, serta turut mendukung kemajuan ilmu pengetahuan di bidang machine learning dan analisis media digital.

DAFTAR PUSTAKA

- [1] Hsiao, C. W., et al., 'Predicting YouTube Video Popularity Using Machine Learning: A Comprehensive Analysis of Engagement Metrics,' dalam IEEE International Conference on Big Data and Smart Computing, 2025.
- [2] Flamino, J., et al., 'Evaluating the Effect of Viral Posts on Social Media Engagement,' Scientific Reports, vol. 15, no. 1, 2025. DOI: 10.1038/s41598-024-84960-6
- [3] Mitchell, D., 'YouTube Trending Videos Dataset,' Kaggle, 2019. [Online]. Tersedia: <https://www.kaggle.com/datasets/datasnaek/youtube-new>. [Diakses: Mei 2026].
- [4] Gupta, V., Diwan, A., Chadha, C., Khanna, A., dan Gupta, D., 'Machine Learning Enabled Models for YouTube Ranking Mechanism and Views Prediction,' dalam AIP Conference Proceedings, vol. 2919, no. 1, 2024.
- [5] Srivastava, P., et al., 'Review on Frameworks Used for Deployment of Machine Learning Model,' International Journal for Research in Applied Science and Engineering Technology (IJRASET), vol. 10, no. 2, 2022. DOI: 10.22214/ijraset.2022.40222
- [6] Liu, H., et al., 'Multi-Modal Video Feature Extraction for Popularity Prediction,' dalam INFORMS 2024 Data Challenge, arXiv:2501.01422, 2025.

[7] Muqri, M. A., et al., 'Using Video Titles to Predict YouTube Video Engagement Using Machine Learning Methods,' Journal of Theoretical and Applied Information Technology (JATIT), vol. 103, no. 8, 2025.

Link Video Presentasi:

<https://youtu.be/0t--EnsHxm8?si=xxnFoMaS4YRwHhSF>